Rede Neural para classificação de tipos de Melanoma

Matheus B. Pereira[1], **Thalita W. Pereira**[2], **Vinicius M. Marcos**[3]

[1]Universidade Estadual do Oeste do Paraná (UNIOESTE)
Caixa Postal 711 – 85.819-110 – Cascavel – PR – Brazil

{matheus.pereira13, thalita.pereira1, vinicius.marcos1}@unioeste.br

Abstract. *This work presents the development of a Convolutional Neural Network (CNN) for the automated classification of seven types of skin lesions, including melanoma. Using the HAM10000 dataset, the model was trained with data augmentation and class balancing techniques to mitigate the bias in the original data. The final architecture, implemented in TensorFlow/Keras, achieved a test accuracy of 85.7% and a macro F1-score of 0.86, demonstrating robust overall performance. However, a detailed analysis revealed challenges in distinguishing between visually similar classes, such as melanoma and nevi. The project culminates in a practical application developed with Streamlit, which allows a user to upload an image and receive the model's classification, thereby validating the solution's real-world applicability and providing a solid foundation for future improvements.*

Resumo. *Este trabalho apresenta o desenvolvimento de uma Rede Neural Convolucional (CNN) para a classificação automática de sete tipos de lesões cutâneas, incluindo o melanoma. Utilizando o dataset HAM10000, o modelo foi treinado com técnicas de aumento de dados (data augmentation) e balanceamento de classes para mitigar o desvio nos dados originais. A arquitetura final, implementada em TensorFlow/Keras, alcançou uma acurácia de 85,7% e um F1-score macro de 0.86 no conjunto de teste, demonstrando um desempenho geral robusto. Uma análise detalhada, contudo, revelou desafios na distinção entre classes visualmente similares, como melanoma e nevos. O projeto culmina em uma aplicação prática desenvolvida com Streamlit, que permite a um usuário submeter uma imagem e receber a classificação do modelo, validando assim a aplicabilidade da solução em um cenário de uso real e fornecendo uma base sólida para futuras melhorias.*

1. Problema Resolvido

O problema abordado nesse trabalho consiste na classificação automática de imagens de lesões cutâneas com o objetivo de auxiliar na diferenciação das mesmas. A tarefa proposta enquadra-se no contexto de classificação multiclasse, uma vez que o modelo desenvolvido recebe como entrada uma imagem e produz como saída uma categoria correspondente ao tipo de melanoma identificado.

O objetivo da aplicação implementada é permitir que o usuário realize o *upload* de uma fotografia dermatoscópica de uma lesão cutânea e receba como resultado a previsão do modelo sobre qual das sete classes a imagem pertence.

2. Arquitetura utilizada

Para a tarefa de classificação de imagens, optamos por construir uma Rede Neural Convolucional (CNN), uma arquitetura de aprendizado profundo que é padrão-ouro para tarefas de visão computacional. A escolha se justifica pela capacidade das CNNs de aprenderem e extraírem características hierárquicas diretamente das imagens, como bordas, texturas e formas complexas, que são fundamentais para diferenciar os tipos de lesões de pele.

Nosso modelo foi estruturado de forma sequencial, composto por quatro blocos de extração de características (blocos convolucionais) e um bloco de classificação (camadas densas), conforme detalhado a seguir:

- **Blocos Convolucionais (1 a 4):** A rede possui quatro blocos convolucionais em sequência, que são o coração da extração de características. Cada bloco é composto por:
  - Uma camada `Conv2D` com um número crescente de filtros (16, 32, 64 e 128, respectivamente) e um kernel de tamanho (3,3) com ativação ReLU.
  - Uma camada de `MaxPooling2D` para reduzir a dimensão espacial dos mapas de características, o que ajuda a tornar o modelo mais eficiente e a focar nas informações mais relevantes.
  - Uma camada de `BatchNormalization` para estabilizar e acelerar o treinamento.
  - Uma camada de `Dropout` com taxas variando entre 0.1 e 0.2 para regularização, prevenindo o sobreajuste.
- **Bloco de Classificação:** Após a passagem pelos blocos convolucionais, os mapas de características resultantes são ”achatados”em um vetor unidimensional pela camada `Flatten`. Este vetor então alimenta as camadas de classificação:
  - Uma primeira camada densa (`Dense`) com 64 neurônios e ativação ReLU, seguida por uma camada de `Dropout` com taxa de 0.3 para uma regularização mais forte antes da decisão final.
  - Uma segunda camada densa com 32 neurônios e ativação ReLU.
  - Por fim, a camada de saída, uma `Dense` com 7 neurônios (um para cada classe de lesão) e função de ativação **Softmax**. A Softmax é crucial aqui, pois converte os valores de saída da rede em uma distribuição de probabilidade, indicando a confiança do modelo para cada uma das sete classes.

Adicionalmente, aplicamos a regularização L2 em todas as camadas convolucionais e na primeira camada densa. Essa técnica ajuda a prevenir o sobreajuste ao penalizar pesos muito grandes na rede, incentivando o modelo a aprender padrões mais simples e generalizáveis.

3. Algoritmo de treinamento utilizado

O treinamento do modelo foi feito utilizando a biblioteca *TensorFlow/Keras*, cuja utilização para criar e treinar modelos de aprendizado profundo [Team 2023]. O algoritmo de otimização adotado foi o **Adam(*Adaptative Moment Estimation*)**, que é um algoritmo que incorpora o conceito de *momentum* aplicando-o aos gradientes escalados [UnB 2021]. A taxa de aprendizado é ajustada a partir do **Adam** de forma adaptativa para cada parâmetro da rede, utilizando médias móveis dos gradientes de primeira e segunda ordem. Devido a essa característica, o algoritmo traz maior estabilidade e velocidade de

convergência, especialmente em problemas de classificação multiclasse, como é o caso das imagens utilizadas.

A função de perda escolhida foi a ***categorical crossentropy***. A Entropia Cruzada Categórica é uma função de perda usada em tarefas de classificação multiclasse, muito utilizada em aplicações de *machine learning*, como: tarefas de classificação de imagens, tarefas de processamento de linguagem natural ou qualquer outro tipo de tarefa de aprendizado de máquina que envolva classificar um exemplo em uma das muitas categorias possíveis [Sorokin 2024].

Para tornar o processo de aprendizado mais eficiente, foram empregados mecanismos de controle conhecidos como ***callbacks***. Um dos mecanismos de controle foi o **ReduceLROnPlateau**, que monitorou a acurácia de validação e reduziu a taxa de aprendizado em um fator de 0,5 sempre que o modelo não apresentava melhora após 10 épocas consecutivas, e o **EarlyStopping**, que monitorou a perda de validação e interrompeu o treinamento após 20 épocas sem ganhos, restaurando os melhores pesos obtidos. Esses mecanismos contribuíram para acelerar a convergência e evitar que o modelo continuasse treinando após obter o melhor resultado.

Além disso, para melhorar a capacidade de generalização, foi utilizado **data augmentation** por meio da classe `ImageDataGenerator`, que aplicou transformações aleatórias às imagens de treino, como rotações, translações, zoom, inversão horizontal e ajustes de escala.

Outro recurso adotado foi o uso de **pesos de classe**, calculados automaticamente a partir da distribuição das amostras, com o objetivo de reduzir o impacto do desbalanceamento do conjunto de dados. Com isso, classes minoritárias, como o melanoma e o dermatofibroma, tiveram maior relevância durante o treinamento do modelo.

4. Parâmetros utilizados na solução desenvolvida

Os principais parâmetros que definiram a solução estão detalhados abaixo:

- **Variáveis de Entrada:** Imagens RGB com dimensões de 28x28 pixels. Cada imagem é representada por um tensor de formato (28, 28, 3).
- **Variáveis de Saída:** Um vetor de 7 posições com probabilidades (via Softmax), onde cada posição corresponde a uma das classes de lesão cutânea.
- **Camadas Ocultas:** 4 camadas convolucionais e 2 camadas densas.
- **Neurônios por Camada:** As camadas convolucionais possuem 16, 32, 64 e 128 filtros, respectivamente. Já as camadas densas possuem 64 e 32 neurônios.
- **Funções de Ativação:** ReLU para as camadas ocultas e Softmax para a camada de saída.
- **Regularização:** Todas as camadas convolucionais e a primeira camada densa utilizam regularização L2. Foram aplicadas também camadas de Dropout com taxas de 0.1, 0.2, 0.2 e 0.1 nos blocos convolucionais, além de 0.3 na camada densa de 64 neurônios.
- **Taxa de Aprendizado:** Inicialmente definida pelo otimizador Adam e ajustada dinamicamente pelo callback `ReduceLROnPlateau`.
- **Otimizador:** Adam.
- **Tamanho do Lote (Batch Size):** 16.

- **Número de Épocas:** O treinamento foi configurado para um máximo de 200 épocas, mas interrompido automaticamente pelo `EarlyStopping` após 20 épocas sem melhora da validação.

5. Resultados e Discussões

O modelo treinado foi rigorosamente avaliado no conjunto de teste, que contém 4.694 imagens não utilizadas durante o treinamento ou validação. Os resultados quantitativos, embora demonstrem um potencial inicial, também revelam desafios importantes na classificação de certas categorias de lesões cutâneas.

O modelo alcançou uma acurácia global de 85,7% no conjunto de teste. A Figura 1 mostra as curvas de aprendizado. Observa-se que a acurácia de treinamento (linha azul) atinge valores elevados, enquanto a acurácia de validação (linha vermelha) estabiliza em um patamar inferior, o que indica que o modelo, embora tenha aprendido, ainda sofre de um certo grau de sobreajuste (*overfitting*). A perda de validação também se mostra consistentemente menor que a de treinamento, reforçando a eficácia dos callbacks para interromper o processo antes de uma degradação severa. Esse comportamento pode ser atribuído, principalmente, ao desequilíbrio da base de dados, que não possui o mesmo número de imagens por classe. Mesmo com a aplicação de técnicas de compensação, como a ampliação artificial de imagens (*data augmentation*), o desbalanceamento ainda favorece o ajuste excessivo do modelo às classes dominantes, assim, dificultando a generalização.

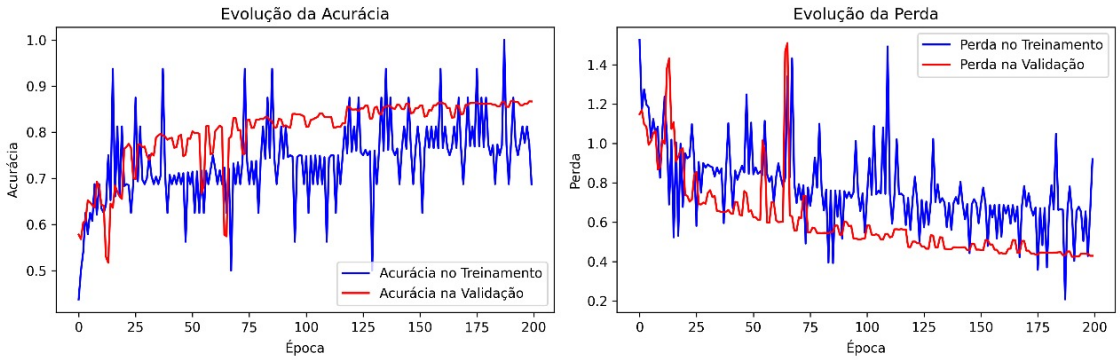

Figura 1. Curvas de Acurácia e Perda durante o treinamento e validação.

A matriz de confusão, apresentada na Figura 2, detalha o desempenho do modelo para cada classe. É possível notar um desempenho excelente para as classes **Dermatofibroma (df)** e **Lesões Vasculares (vasc)**, que foram classificadas com quase 100% de acerto. No entanto, o modelo exibe dificuldades em distinguir entre as classes **Lesões Benignas (bkl)**, **Nevos Melanocíticos (nv)** e **Melanoma (mel)**. Evidentemente, 89 imagens de ‘bkl‘ e 111 de ‘nv‘ foram incorretamente classificadas como ‘mel‘, o que representa um ponto crítico de melhoria, embora seja preferível um falso positivo para melanoma do que um falso negativo.

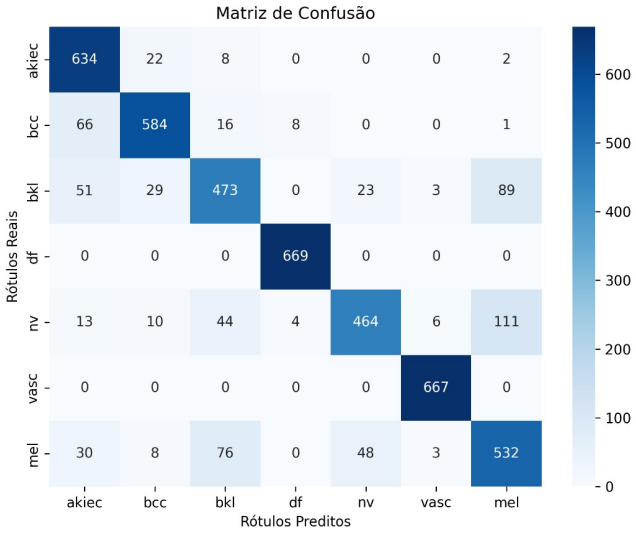

Figura 2. Matriz de confusão no conjunto de teste.

O relatório de classificação (Tabela 1) fornece as métricas de precisão, recall e F1-score. O F1-score macro de 0.86 indica um desempenho geral bom/satisfatório, mas a análise por classe revela a disparidade. Classes como ‘df‘ e ‘vasc‘ atingem um F1-score de 0.99, enquanto ‘bkl‘ (0.74), ‘nv‘ (0.78) e ‘mel‘ (0.74) apresentam os maiores desafios, o que reforça a análise da matriz de confusão. O recall de 95% para ‘akiec‘ é um ponto positivo, mostrando que o modelo é eficaz em identificar esta classe quando ela está presente.

Tabela 1. Relatório de Classificação no Conjunto de Teste.

Classe	Precisão	Recall	F1-Score	Suporte
akiec	0.80	0.95	0.87	666
bcc	0.89	0.87	0.88	675
bkl	0.77	0.71	0.74	668
df	0.98	1.00	0.99	669
nv	0.87	0.71	0.78	652
vasc	0.98	1.00	0.99	667
mel	0.72	0.76	0.74	697
Média Macro	**0.86**	**0.86**	**0.86**	**4694**
Média Ponderada	**0.86**	**0.86**	**0.86**	**4694**

Para ilustrar a aplicação prática do modelo, a Figura 3 mostra dez exemplos de inferência. Esta análise qualitativa confirma visualmente o comportamento do modelo: ele acerta com confiança em casos claros (‘akiec‘, ‘bkl‘, ‘vasc‘, ‘mel‘, ‘nv‘), mas também comete erros em imagens mais ambíguas, como a confusão entre ‘bcc‘ e ‘bkl‘.

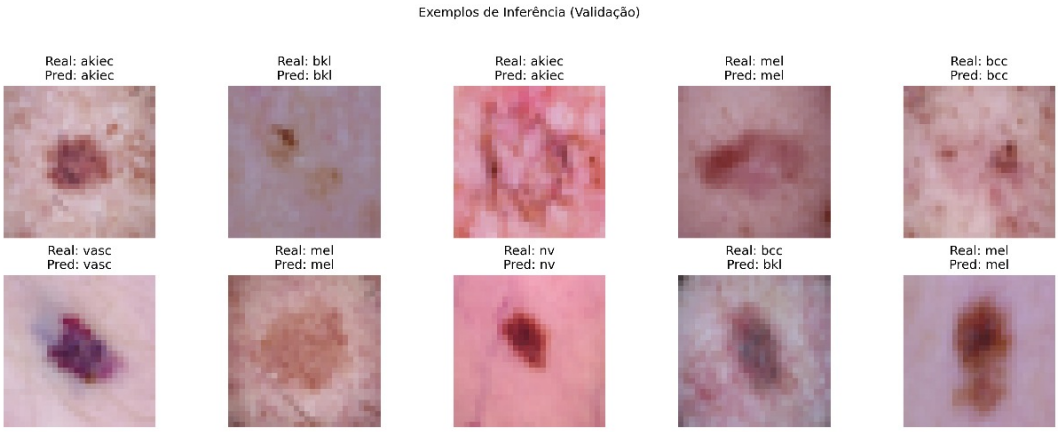

Figura 3. Exemplos de inferência no conjunto de validação, comparando o rótulo real com a predição do modelo.

5.1. Conclusão

Os resultados obtidos demonstram que a arquitetura de Rede Neural Convolucional, combinada com as técnicas de pré-processamento e regularização, foi capaz de criar um modelo com bom desempenho geral, evidenciado pela acurácia de 85,7% e F1-score de 0.86. O modelo se mostrou extremamente eficaz para identificar lesões como Dermatofibroma e Lesões Vasculares.

Contudo, a análise detalhada revela uma dificuldade na distinção entre classes visualmente semelhantes, como melanoma, nevos e lesões benignas. Este é um desafio conhecido e amplamente documentado na área de dermatologia computacional, onde até mesmo algoritmos avançados apresentam confusão entre lesões malignas e benignas devido à alta similaridade de suas características morfológicas [Esteva et al. 2017]. O leve sobreajuste e a confusão entre classes críticas sugerem que trabalhos futuros podem se beneficiar da exploração de arquiteturas mais complexas (como ResNet ou EfficientNet), técnicas de *fine-tuning* em modelos pré-treinados em datasets maiores (como o ImageNet) e métodos de *data augmentation* mais avançados. Ainda assim, o projeto cumpre seu objetivo ao entregar um classificador funcional e uma base sólida para futuras melhorias.

Referências

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., and Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639):115–118.

Sorokin, M. (2024). Entropia cruzada categórica: desvendando seus potenciais na classificação multiclasse. https://medium.com/@vergotten/categorical-cross-entropy-unraveling-its-potentials-in-multi-class classification-705129594a01.

Team, T. T. (2023). Keras: The high-level api for tensorflow. https://www.tensorflow.org/guide/keras?hl=pt-br.

UnB, I. C. (2021). Algoritmos de otimização com taxa de aprendizado adaptativa. https://medium.com/@ieeecisunb/algoritmos-de-otimiza